Продажи: от строк к решениям

Проект 01 · UCI Online Retail · январь-ноябрь 2011 · Python / SQL / контроль качества

Оборот после отмен

£8 587 247

Сумма строк продаж минус строки отмен

Заказы с продажами

17 582

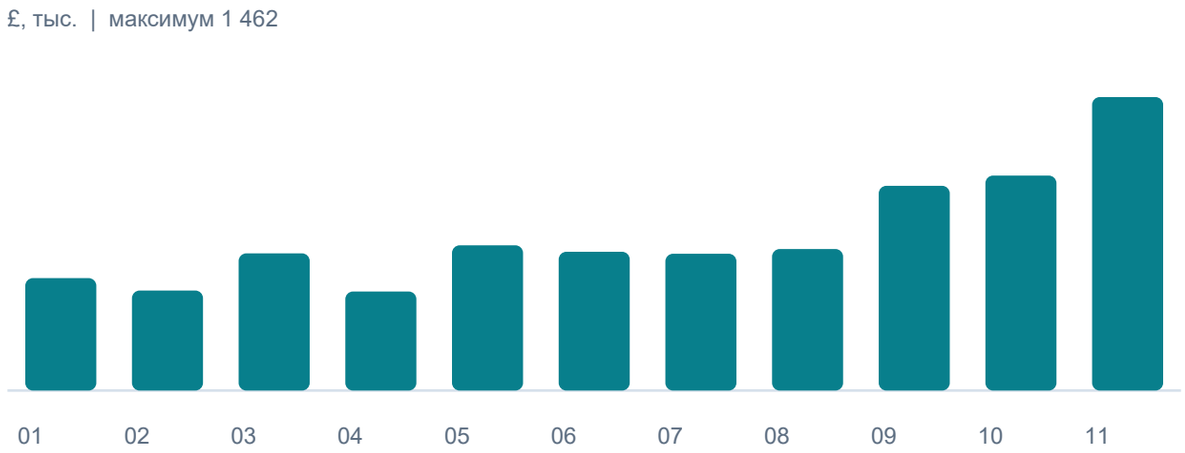
Уникальные InvoiceNo, положительные продажи

Сумма отмен / продажи

6,7%

Стоимостное отношение; не доля возвращённых заказов

Оборот по полным месяцам



Что видно в данных

Пиковый месяц: 2011-11, оборот после отмен £1 461 756.

На Великобританию приходится 83,2% оборота после отмен.

Декабрь 2011 исключён: в источнике он неполный. Сравнение с полным ноябрём исказило бы тренд.

Решение для обсуждения: проверить причины отмен и структуру крупных заказов; для выводов о повторяющейся сезонности нужны дополнительные годы. Эти данные не доказывают влияние маркетинга и не содержат расходов для расчёта ROI.

Источник: Chen, D. (2015), UCI Online Retail, DOI 10.24432/C5BW33, CC BY 4.0. Открытые данные; очистка и агрегация.

Когорты и качество данных

Проект 01 · первая наблюдаемая покупка · пропуски, дубли и цензура наблюдения

Возврат к покупке в M1

19,9%

Взвешенно по когортам января-октября 2011

Нет CustomerID в источнике

24,9%

Выручка учитывается; когорты - только известные ID

Повторяющиеся строки

5 268

Сохранены: нет надёжного идентификатора строки

Повторная покупка по когортам

	M0	M1	M2	M3	M4	M5
2010-12	100%	37%	32%	38%	36%	40%
2011-01	100%	22%	27%	23%	32%	29%
2011-02	100%	19%	19%	28%	27%	25%
2011-03	100%	15%	25%	20%	22%	17%
2011-04	100%	21%	20%	21%	20%	23%
2011-05	100%	19%	17%	17%	21%	23%
2011-06	100%	17%	16%	26%	23%	33%
2011-07	100%	18%	21%	22%	27%	—
2011-08	100%	21%	25%	24%	—	—
2011-09	100%	23%	30%	—	—	—
2011-10	100%	24%	—	—	—	—
2011-11	100%	—	—	—	—	—

Правила, которые важны

Первая покупка - первая наблюдаемая в данных, а не доказанная дата привлечения клиента.

Недоступные будущие месяцы показаны прочерком. Они не превращены в нулевое удержание.

После удаления точных дублей оборот изменился бы на £18 541. Это анализ чувствительности, а не основание удалить строки.

SQL проверен независимыми расчётами pandas: суммы, размеры когорт и повторные покупки.

Источник: Chen, D. (2015). Online Retail. UCI Machine Learning Repository. DOI: 10.24432/C5BW33. CC BY 4.0. Анализ и визуализации являются преобразованием исходных данных.

A/B-тест: эффект и неопределённость

Проект 02 · СИНТЕТИЧЕСКИЕ ДАННЫЕ · 24 000 участников · фиксированный горизонт

Изменение конверсии B − A

+1,35 п.п.

Основная метрика: конверсия за 7 дней

95% доверительный интервал

0.53…2.17 п.п.

Newcombe / Wilson, разница долей

Двустороннее p-value

0.0012

Порог 0,05 задан до расчёта

Конверсия по группам



Решение в рамках симуляции

Конверсия B выше A, интервал не включает ноль.

Проверка SRM: p = 0.416; при пороге 0,01 значимого перекоса групп не обнаружено.

Знаменатель - все назначенные участники. У каждого завершилось 7-дневное окно наблюдения.

Это результат сгенерированного эксперимента, не рост показателей реальной компании.

Ограничения и проверка: генератор, seed и SQL включены в комплект. Один основной тест, без повторного просмотра p-value и без выбора удачного seed. Выручка на участника - дополнительная исследовательская метрика. Реальное внедрение потребовало бы проверки бизнес-ограничений и качества эксперимента.